

Кейс 1

Анализ архивных показаний качества воздуха в Атырау, Актау и Актобе

Преподаватель: Zhanar Oralbekova

Редакция от 26 сентября 2026 года

Данные, код, модели и результаты входят в исследовательский пакет. Происхождение данных и границы выводов указаны в отчёте.

Работа подготовлена с существенной ИИ-помощью. Подробности раскрыты в AI_USAGE_DISCLOSURE.md. Перед защитой студенту необходимо самостоятельно проверить расчёты и разобраться в методах.

Исходный кейс №1. Assessment and Analysis of Air Pollution Levels in Major Cities of Kazakhstan.

Курс: Artificial intelligence and machine learning. Assignment 1. Период анализа: 2022–2025.

Статус: PARTIAL — вычислительное исследование завершено; экологическая интерпретация ограничена неразрешённой проверкой измерительных каналов.

Аннотация

Исследование сопоставляет фиксированные пункты наблюдений трёх городов западного Казахстана и проверяет, насколько метеорологические условия объясняют архивный показатель PM_{2.5}. На 1124 общих пригодных датах средняя опубликованная PM_{2.5} на посту № 32 в Атырау составляет 54.298 мкг/м³. Это наибольшее значение среди выбранных станций, но не доказанный рейтинг загрязнения городов: PM_{2.5} превышает парную PM₁₀ в 845 из 1209 суток. Дополнительный временной ML-эксперимент не показывает устойчивого выигрыша над простым средним. Его MAE на 304 сутках итоговой проверки равна 23.708 мкг/м³. Приоритетная рекомендация — восстановить проверяемую метрологическую цепочку, затем оценивать меры снижения воздействия. Все результаты рассчитаны по сохранённым CSV. Исходное вычисление: 25.09.2026; повторный научный аудит и редакция: 26.09.2026. Используются реальные опубликованные измерительные записи, а не синтетические данные. Однако принадлежность записи архиву не подтверждает исправность канала: нужна независимая проверка калибровки. Работа выполнена с раскрываемой ИИ-помощью; авторские реквизиты студента не установлены и не выдуманы.

1. Проблема и исследовательские вопросы

В локальном экологическом анализе важно различать измеренную концентрацию, индекс качества воздуха и оценку воздействия на население. Здесь объект — суточное показание конкретной станции. Городская экспозиция, доли источников и медицинские исходы не наблюдаются. Поэтому работа отвечает на пять вопросов Task 1 на уровне доступного доказательства: какая выбранная станция имеет более высокие архивные показания; какие вещества чаще превышают сопоставимые ориентиры; что известно об источниках из литературы; меняются ли показания по сезонам; какие действия реалистичны в ближайшие 5–10 лет.

Атырау — основной объект. Актау и Актобе добавлены из того же национального архива для единого происхождения и частоты. В каждом городе фиксируется один пункт, чтобы меняющийся состав сети не создавал ложный тренд. Такой дизайн улучшает временную сопоставимость и одновременно ограничивает пространственную: один пост не представляет все жилые районы. Число постов, отсутствующие параметры и различия полноты рассматриваются как часть результата, а не скрываются.

2. Обзор первоисточников

Казгидромет описывает наблюдения в промышленной зоне Атырау и перечень контролируемых примесей [3]. Это подтверждает существование мониторинга, но не является доказательством доступности длинного почасового архива. Для эмпирического анализа выбран открытый архив AirData.kz, который публикует значения с исходными единицами и документацией очистки [1, 2]. Бюро национальной статистики публикует годовые индикаторы [4]; они подходят для широкого контекста, но не заменяют суточные записи.

Исследование Yessenamanova и соавторов использовало мониторинг H₂S в Атырау за ограниченный период 2020 года [10]. Его пространственная неоднородность обосновывает необходимость нескольких станций. При этом заключение статьи прямо признаёт

неопределённость источника отдельных выбросов; переносить результат на наши годы или рассчитывать долю АНПЗ по корреляции нельзя. Региональная инвентаризация за 2018–2022 годы отдельно рассматривает стационарные источники, автотранспорт и отопление [9]. Это основание обсуждать соответствующие направления политики, но областной инвентаризационный объём выбросов не равен концентрации в точке.

ВОЗ 2021 задаёт ориентиры концентраций и времени усреднения [5, 6]. Они не являются юридически обязательными стандартами. Национальный приказ № ҚР ДСМ-70 содержит отдельные среднесуточные и максимально разовые ПДК [7]. В работе выполняется описательное сопоставление с текущей прочитанной редакцией; ретроспективная квалификация правонарушений не проводится.

Сопоставление этих источников определяет дизайн исследования. Инвентаризация описывает массу выбросов и категории объектов, станционные ряды — концентрацию после переноса и рассеивания, а рекомендации ВОЗ — ориентиры воздействия. Эти три уровня нельзя подменять друг другом. Поэтому здесь не рассчитываются проценты вклада завода и транспорта: для них потребовались бы совместимые сведения о выбросах, химическом составе и переносе примесей. Исследование H₂S в Атырау охватывало 32 дня с сентября по октябрь 2020 года и восемь пунктов [10]; оно полезно как пример пространственного дизайна, но не подтверждает сезонность PM_{2.5} в 2022–2025 годах.

Пробел, который закрывает настоящая работа, — проверяемое соединение архивных записей, полноты и простых моделей в одной локальной задаче. При этом документация набора [2] описывает ретроспективные фильтры, а не протокол поверки каждого датчика. Поэтому воспроизводимость вычислений рассматривается отдельно от экологической достоверности. Отрицательный результат модели и обнаруженное противоречие каналов имеют самостоятельное исследовательское значение: они указывают, какие доказательства нужны до содержательной интерпретации показаний.

3. Происхождение и проверка данных

Зафиксирован commit AirData.kz 0fe9a615baf614346e282796f685ce72b852187f. Для семи загрязнителей получены полные gzip-архивы; SHA-256 и URL сохранены в results/download_manifest.csv. Исходное наблюдение — запись станции за час. После фильтрации трёх городов, периода и проверки конечности значений сохранено 1054818 записей по всем доступным станциям и веществам. Значения mg/m³ проверены против value_ugm3=raw_value×1000. Собственная проверка не выявила несовпадений пересчёта, отрицательных значений или дубликатов station_id–time; это ожидаемо для уже очищенного поставщиком архива и не означает, что приборы исправны.

Пост № 32 в Атырау обозначен PCP #8 и имеет координаты 47.096617, 51.942701. Сравниваемые станции — Актау, пост № 22 и Актобе, пост № 31. Строки времени содержат явные смещения –07/–08 несмотря на название datetime_utc: код сохраняет абсолютный момент по указанному offset, затем переводит в Asia/Atyrau (UTC+5). Смысл этих исходных смещений нуждается в подтверждении поставщика. Исходные строки не переписываются под желаемую локальную дату.

Погода получена отдельно из ERA5 через Open-Meteo для точки Атырау, пост № 32: температура, относительная влажность, ветер и осадки [8]. Это пространственный реанализ, а не датчик на станции. Он используется только в одновременной объяснительной задаче; здесь не делается предположение о доступности реанализа в реальном времени.

Таблица 1. Полнота суточной PM2.5 Атырау, пост № 32. Условие пригодности — минимум 18 уникальных часов из 24.

Год	Пригодные сутки	Календарные сутки	Полнота
2022	338	365	92.6%
2023	356	365	97.5%
2024	211	366	57.7%
2025	304	365	83.3%




Рисунок 1. Полнота выбранных станций

Из 1461 календарных суток Атырау пригодны 1209; 252 отсутствуют или неполны. Особенно разрежен 2024 год. Пропуски не превращены в нули и не заполнены для оценки. Фильтр 18 часов — аналитическое правило полноты, а не утверждение о выполнении всех требований государственного мониторинга.

4. Методология и контроль качества

Для каждой пары станция–вещество рассчитана средняя доступных часов суток; при недостатке часов целевая величина остаётся пропущенной. Межгородское сравнение PM2.5 ограничено пересечением пригодных дат. Анализ каждого вещества использует собственный явно указанный знаменатель. Рассчитываются распределения, месячные средние, сезонные таблицы и ранговая корреляция Spearman с погодой. Графики не соединяют искусственно восстановленные целевые метки.

Критическая дополнительная проверка сопоставляет вложенные фракции частиц. На посту № 32 в Атырау PM2.5 больше PM10 в 845 из 1209 парных суток (69.9%); в 280 случаях разница превышает 20%. Неодинаковые приборы и ошибки измерений могут давать отдельные несоответствия, однако столь частое расхождение требует проверки маркировки каналов, единиц и калибровки. На посту № 31 в Актобе отмечена необычно малая вариативность PM2.5. Значения не исправлены произвольным коэффициентом, а дни не исключены ради красивого рейтинга.

Объяснительная модель оценивает PM2.5 того же дня по ERA5 и циклическому календарю. Обучение — 2022–2023, валидация — 2024, итоговая проверка — 2025. Ridge выбирается из $\alpha=0.1, 1, 10$; Random Forest — 200 деревьев, глубина 8, минимальный лист 3 или 10. Критерий выбора — MAE на валидации. Медиана для заполнения признаков и StandardScaler обучаются только на обучающей части. После выбора выполняется повторное обучение на обучающей и валидационной частях. Простое среднее обучающего периода является обязательным контрольным ориентиром. Все метрики итоговой проверки рассчитываются по одним датам. Это не прогноз будущего — для него выделен отдельный кейс №10.

5. Результаты: сравнение станций и веществ

Таблица 2. PM2.5 на общих пригодных датах. Среднее и медиана — мкг/м³. Последние столбцы показывают число и долю суток выше суточного ориентира ВОЗ 15 мкг/м³.

Город	Сутки	Среднее	Медиана	Выше 15: сутки	Выше 15: %
Актау	1124	2.359	1.253	13	1.157
Актобе	1124	1.459	1.449	0	0.000
Атырау	1124	54.298	54.507	1093	97.242




Рисунок 2. Сопоставление архивных показаний

Ответ на вопрос о наиболее загрязнённом городе ограничен: в скачанном архиве выше показатель Атырау, пост № 32. На основании проверки фракций нельзя надёжно превратить это в вывод о наиболее загрязнённом городе Казахстана или даже реальном ранге экспозиции этих трёх городов. Отсутствие превышений на другом посту также не доказывает безопасность воздуха в городе.

Таблица 3. Атырау, пост № 32: суточные ориентиры ВОЗ и отдельные знаменатели по веществам.

Вещество	Ориентир, мкг/м ³	Пригодные сутки	Выше: сутки	Выше: %
CO	4000.000	1208	0	0.000
NO ₂	25.000	1012	5	0.494
PM10	45.000	1209	751	62.117
PM2.5	15.000	1209	1176	97.270
SO ₂	40.000	529	11	2.079




Рисунок 3. Частота превышения ориентиров ВОЗ

Частоту превышения можно использовать для первичного отбора каналов на проверку. Нельзя ранжировать токсичность просто по числу микрограммов. Для H₂S и O₃ достаточного сопоставимого суточного ряда выбранного поста нет; суточный ВОЗ-порог для H₂S не выдуман, а восьмичасовой критерий O₃ не приложен к суточным средним. ВОЗ суточный уровень соответствует 99-му перцентилю распределения; простая доля дней выше него — описательная статистика, не самостоятельная процедура сертификации соответствия.

Таблица 4. Сопоставление с национальными среднесуточными величинами из текущей прочитанной редакции № ҚР ДСМ-70. Единицы переведены из mg/m³ в мкг/м³; не используются максимально разовые значения.

Вещество	Ориентир, мкг/м ³	Пригодные сутки	Выше: сутки	Выше: %
CO	3000.000	1208	0	0.000
NO ₂	40.000	1012	3	0.296
PM10	60.000	1209	451	37.304
PM2.5	35.000	1209	1054	87.179
SO ₂	50.000	529	7	1.323

6. Время, сезоны и метеоусловия




Рисунок 4. Месячные средние по пригодным суткам




Рисунок 5. Атырау, пост № 32: сезонная структура по годам

Таблица 5. Сезонные значения PM2.5 Атырау, пост № 32, мкг/м³; n — наблюдаемые пригодные сутки.

Год	Сезон	Сутки	Среднее
2022	Весна	88	67.987
2022	Зима	80	74.553
2022	Лето	83	76.688
2022	Осень	87	74.952
2023	Весна	87	59.183
2023	Зима	87	61.458
2023	Лето	92	59.546
2023	Осень	90	61.629
2024	Весна	92	33.369
2024	Зима	60	46.352
2024	Лето	21	39.670
2024	Осень	38	48.929
2025	Весна	91	43.993

Год	Сезон	Сутки	Среднее
2025	Зима	60	31.492
2025	Лето	92	37.831
2025	Осень	61	30.618

Единого устойчивого зимнего максимума во все годы эта таблица не подтверждает. Межгодовые уровни меняются, часть сезонных клеток имеет заметно меньше наблюдений. Поэтому разделение на календарные сезоны здесь описательное: полноценную сезонную декомпозицию с заполненными пробелами нельзя интерпретировать как наблюдаемую ежегодную закономерность. Наблюдаемый спад не приписывается конкретной экологической политике: могут влиять калибровка, изменение канала, отбор провайдером и пропуски.

Spearman(PM2.5, температура)=-0.033; с ветром — 0.028; с влажностью — 0.034. В текущей выборке это слабые монотонные связи. Нулевая агрегированная связь не исключает отдельных метеорологических эпизодов и тем более не доказывает отсутствие выбросов.




Рисунок 6. Одновременные метеорологические ассоциации

7. Реально обученный объяснительный эксперимент

Таблица 6. Отложенная проверка на данных 2025 года. MAE и RMSE — мкг/м³, R² безразмерен.

Модель	MAE	RMSE	R²	Сутки
Среднее обучения	23.708	25.211	-7.504	304
Ridge	23.707	26.561	-8.439	304
Случайный лес	24.593	27.584	-9.180	304




Рисунок 7. Сравнение объяснительных моделей

По валидации выбрано среднее обучающего периода. Незначительное различие MAE между Ridge и baseline на итоговой проверке не меняет заранее выбранную модель. Все R^2 отрицательны: ошибка существенно больше вариации целевой переменной вокруг среднего самого test. Сдвиг уровня между 2022–2023 и 2025 годами объясняет, почему простая экстраполяция обученного среднего особенно неудачна. Погода и календарь не обеспечили переносимость. Дополнительное блочное пересэмплирование парных ошибок даёт для разницы MAE Ridge минус среднее -0.002 мг/м³ и приблизительный 95%-й диапазон $[-1.680; 1.738]$ при блоке 14 суток. Столь малое различие нельзя считать устойчивым преимуществом. Методика и ограничения этой последующей проверки описаны в `results/revision_analysis_metadata.json` и [12]; модели не переобучались. Это отрицательный эмпирический результат, а не основание менять границы test.

Предсказания, остатки, результаты перестановки признаков, фактические параметры и веса сохранены. Перестановочная важность — чувствительность обученной модели; при слабой общей модели она не даёт доказательства причинного вклада погоды. Коррелированные погодные признаки дополнительно ограничивают её интерпретацию.

8. Источники, риски и рекомендации

Промышленность, энергетика, отопление и транспорт рассматриваются как документированные региональные направления [3, 9], а не количественно оценённые причины каждой точки графика. Диаграмма долей источников не построена: нет сопоставимой локальной инвентаризации массы выбросов, химического состава и модели переноса, позволяющей оценить эти доли. Последствия для здоровья обсуждаются только на уровне общего обоснования мониторинга ВОЗ. Число заболеваний, смертей или индивидуальный риск по этой выборке не рассчитывались.

В течение ближайшего года практический приоритет — аудит каналов № 32, 22 и 31, сопоставление с паспортами приборов и ручными/референсными пробами, публикация происхождения флагов качества и истории калибровки. Затем следует восстановить многопостовую сеть с гарантированной доступностью временных архивов и регистрировать время публикации записи. Для информации населению использовать официальные сообщения, а не этот экспериментальный прогноз.

На горизонте 1–3 лет полезны верификация инвентаризации выбросов, прицельные измерения рядом с промышленными и транспортными объектами, сезонные кампании H_2S и PM, документирование ремонтов и смены приборов. На 5–10 лет возможны модернизация очистки

выбросов, повышение энергоэффективности и транспортные меры, но выбор и бюджет должны опираться на дополнительное исследование источников. Наблюдаемые различия архива не являются рассчитанной экономической выгодой какой-либо меры.

Дополнительная проверка станции Атырау, пост № 235

Выявленная проблема не относится автоматически ко всей сети. У PCP #10 (ID 235) исходное сравнение суточных средних даёт один случай $PM_{2.5} > PM_{10}$ из 1300; ниже показано, что при выравнивании часов он исчезает, у более коротких рядов 33 и 86 таких случаев в проверенном периоде нет. Это делает 235 разумным кандидатом для следующей независимой проверки, но само согласие фракций не удостоверяет калибровку. В дополнительном исследовательском эксперименте кейса №10 на 235 сохранены признаки, годы split и уже выбранные на 32 гиперпараметры; настройки по 235 не проводились. На 353 отложенных сутках persistence имеет MAE 2.928 мкг/м³. Основной заранее зафиксированный эксперимент 32 не заменён. Этот анализ добавлен после проверки качества, является дополнительным исследовательским и не устраняет ограничения времени публикации и ретроспективного QC. Подробная таблица находится в отчёте кейса №10 и results/sensitivity235.

Дополнительная проверка 26.09.2026: одинаковые часы

Первоначальное сравнение суточных средних допускает, что $PM_{2.5}$ и PM_{10} наблюдались в разные часы. При повторном аудите записи соединены по городу, посту и точному временному штампу; обе средние рассчитаны заново только по общим часам. В таблицу входят сутки с минимум 18 такими парами. Это последующая проверка устойчивости, а не изменение основной выборки или отбор удобных дней.

Таблица 7. Сравнение фракций Атырау после выравнивания часов.

Пост	Парные сутки	$PM_{2.5} > PM_{10}$: сутки	Разница >20%: сутки
235	1300	0	0
32	1209	845	280

На посту № 32 остаются 845 несоответствий: различное часовое покрытие не объясняет основной сигнал. На посту № 235 прежний единственный случай исчезает: 0 из 1300 суток. Поэтому первоначальный показатель 1/1300 нельзя трактовать как подтверждённую аномалию этого поста. Небольшие межприборные различия сами по себе не доказывают ошибку; частота и расхождения более 20% на посту № 32 требуют проверки приборов.

Дополнительно правило полноты ужесточено с 18 до 24 часов без изменения исходных значений. На 1003 общих датах трёх постов среднее Атырау равно 53.917 мкг/м³. Порядок архивных средних сохраняется; метрологическое ограничение остаётся. Полная таблица сохранена в results/completeness_sensitivity.csv.

9. Ограничения и ответы на вопросы Task 1

Самое существенное ограничение — непроверенная физическая согласованность РМ-каналов выбранного поста № 32. Дополнительно действуют выборочность станций, пропуски, неизвестное время фактической доступности записей и ретроспективная очистка AirData.kz. Процедуры соседних скачков и пространственных выбросов поставщика могут опираться на последующие наблюдения; этот архив нельзя безоговорочно считать доступным в исходном виде в прошлом.

RQ1: максимальный архивный показатель среди выбранных постов — Атырау, пост № 32; рейтинг городов не подтверждён. RQ2: таблица 3 показывает частоту превышений доступных

веществ, но не полный перечень рисков. RQ3: литература указывает направления источников, их доли не установлены. RQ4: сезонные различия есть, устойчивый одинаковый зимний максимум не подтверждён. RQ5: сначала метрология и полнота, затем проверяемая оценка источников и мер. Каждая формулировка относится к фактически доступному доказательству.

10. Заключение и воспроизводимость

Создан проверяемый путь от опубликованных почасовых записей к суточным таблицам, графикам и реальному ML-эксперименту. Основное содержательное открытие — ограничение достоверности, которое обнаруживается при совместном анализе PM_{2.5} и PM₁₀. Кейс имеет статус PARTIAL до получения метаданных каналов и независимой проверки калибровки. Код, веса и вычисления доступны для проверки, но это не заключение о санитарной безопасности.

Запуск из корня пакета: `python 01_Air_Pollution/pipeline.py --case 1`. Проверка сохранённых метрик: `python 01_Air_Pollution/pipeline.py --verify`. Отдельно выполненный Notebook воспроизводит расчёты из чистого kernel. Источники, хеши, `quality_checks` и `limitations` позволяют проверить происхождение каждого числа.

Литература

1. AirData.kz / Global Shapers Almaty Hub. Open Air Quality Dataset for Kazakhstan. Kazakhstan; 2020–2026. URL: <https://github.com/qazybekb/AirDataKz-OpenData> (обращение: 25.09.2026).
2. AirData.kz. Datasheet for Dataset: AirData.kz Open Air Quality Data. Kazakhstan; 2017–2026. URL: <https://github.com/qazybekb/AirDataKz-OpenData/blob/0fe9a615baf614346e282796f685ce72b852187f/DATASHEET.md> (обращение: 25.09.2026).
3. РГП Казгидромет. Мониторинг промышленной зоны Атырау. Атырау; 2021. URL: <https://www.kazhydromet.kz/ru/post/1063> (обращение: 25.09.2026).
4. Bureau of National Statistics of Kazakhstan. 21.2.a Air quality. Kazakhstan; annual since 2014. URL: <https://stat.gov.kz/en/open-data/pollution/482928/> (обращение: 25.09.2026).
5. World Health Organization. WHO global air quality guidelines. Global; 2021. URL: <https://www.who.int/publications/i/item/9789240034228> (обращение: 25.09.2026).
6. World Health Organization. What are the WHO Air quality guidelines?. Global; 2021. URL: <https://www.who.int/news-room/feature-stories/detail/what-are-the-who-air-quality-guidelines> (обращение: 25.09.2026).
7. Министерство здравоохранения Республики Казахстан. Об утверждении Гигиенических нормативов к атмосферному воздуху. Kazakhstan; 2022, amended 2025. URL: <https://old.adilet.zan.kz/rus/docs/V2200029011> (обращение: 25.09.2026).
8. Open-Meteo / Copernicus / ECMWF. Historical Weather API, ERA5. Атырау ERA5 grid point; 2022–2025. URL: <https://open-meteo.com/en/docs/historical-weather-api> (обращение: 25.09.2026).
9. Гидрометеорология и экология. Инвентаризация источников загрязнения атмосферного воздуха Западно-Казахстанского региона. Western Kazakhstan four regions; 2018–2022. URL: <https://journal.kazhydromet.kz/kazgidro/article/view/2341> (обращение: 25.09.2026).
10. M. Yessenamanova, Z. Yessenamanova, A. Tlepbergenova, G. Batyrbayeva. Analysis of the Content of Hydrogen Sulfide in the Air of the City of Атырау. Атырау; 2020 observations; published 2021. URL: <https://www.iieta.org/journals/ijsdp/paper/10.18280/ijsdp.160308> (обращение: 25.09.2026).

11. scikit-learn developers. Lagged features for time series forecasting. Methodological; accessed 2026. URL: https://scikit-learn.org/stable/auto_examples/applications/plot_time_series_lagged_features.html (обращение: 25.09.2026).

12. Hans R. Künsch. The Jackknife and the Bootstrap for General Stationary Observations. *Annals of Statistics* 17(3), 1217–1241. Methodological; 1989. URL: <https://doi.org/10.1214/aos/1176347265> (обращение: 26.09.2026).