

Можно ли предсказать следующие сутки PM2.5?

Лаговые признаки, честная проверка и границы применимости

Атырау, РСР #8 — пост № 32 · Исходный кейс № 10 | 2022–2025 · Редакция 26 сентября 2026 года

Искусственный интеллект и машинное обучение

Сначала фиксируем момент и цель прогноза

Известно к моменту выпуска

Предыдущие опубликованные значения

Календарь следующего дня

Фиксированные параметры модели

Оцениваем после окончания суток

Среднее PM2.5 за $[t, t+1)$

Минимум 18 наблюдённых часов

Никакой фактической будущей погоды

Доступность лагов уменьшает выборку

1209

пригодных суточных целей

101

исключено из-за лагов

1108

строк для сравнения
моделей

Одна строка — будущие сутки и исторические признаки
Пропущенные целевые величины не восстановлены

Временное разделение сохраняет направление прогноза



Обучение: 631 •
валидация: 204 •
проверка: 273 суток

Годы разделены до
оценки моделей

В признаки не попадают будущие измерения

История канала

Лаги 1, 2, 3, 7, 14 суток

Средние за 3, 7, 14 суток

Разброс за 7 суток

Календарь

Синус и косинус дня года

Синус и косинус дня недели

Никаких измерений дня цели

Простые правила — обязательная точка сравнения

Метод	Правило или параметры
Вчерашнее значение	Прогноз = $PM_{2.5}(t-1)$
Неделю назад	Прогноз = $PM_{2.5}(t-7)$
Ridge	α выбран по валидации
Случайный лес	200 деревьев; глубина ≤ 8

Модели действительно обучены; контрольные правила заданы явно

Валидация выбирает вчерашнее значение

6,273


MAE на валидации, мкг/м³

$t - 1$

выбранное контрольное правило

Основной критерий — MAE
Выбор зафиксирован до итоговой проверки


На основном посту обучение не уменьшило MAE



273 одинаковых целей
2025 года

Правило «вчера»: MAE
3,686 мкг/м³

Прогноз следует за последним наблюдением



Разрывы линии означают
отсутствие пригодных
данных

Низкая средняя ошибка
не гарантирует
предупреждение о скачке

Прогноз высоких эпизодов пока не оценён

80,590

порог P90 прошлого периода, мкг/м³

0

отложенных суток выше порога

Порог взят из прошлого периода и не снижен после проверки
Нет оснований заявлять качество предупреждений

Другой пост: фиксированная методика без настройки



Модель	MAE	RMSE	R ²
Вчерашнее значение	2,928	5,430	0,490
Неделю назад	4,609	8,231	-0,171
Ridge	3,071	4,977	0,572
Случайный лес	2,912	4,915	0,583

РСР #10, пост № 235 — дополнительный исследовательский анализ

353 отложенных суток; гиперпараметры взяты с поста № 32

Малый выигрыш леса на посту № 235 неустойчив

Дополнительная проверка: 95% диапазоны блочного пересэмплирования
Блок 14 суток; отрицательная разница означает меньшую ошибку



Разница MAE лес –
«вчера»: $-0,017 \text{ мкг/м}^3$

95%-й диапазон
пересэмплирования:
[$-0,312$; $0,278$]

Три барьера перед реальным применением

Измерение

Маркировка и поверка канала

Сопоставление с независимым прибором

Доступность и оценка

Журнал фактической публикации

Версии до ретроспективной очистки

Новый заранее сохранённый период

Простой ориентир остаётся честным результатом

В основной проверке выигрыша от обучения нет

На посту № 235 небольшой выигрыш леса неустойчив

Следующий шаг — проверить данные и новый будущий период

Источники, код и раскрытие помощи ИИ

Источники

AirData.kz — наблюдения и ретроспективный контроль

scikit-learn — пример временных лаговых признаков

Künsch (1989) — блочное пересэмплирование

Методы и данные

ВОЗ (2021) — ориентиры воздействия

Точные данные, версии и параметры — в пакете